有据 · 投资问答助手

有据可查的投资问答助手 · 示例证券。题目：AI 投顾 / 智能问答运营与合规边界；场景：券商 App 内「投教助手」+ 运营后台（券商为虚构的「示例证券」，知识库为匿名构造）

投资问题，有据可答。开户、交易规则、产品知识随问随答；每句回答可点开出处；涉及风险较高的产品按用户风险等级提示；答不了直接转人工。合规要求作为内置底线在后台运行，见下方「核心设计」。项目原名「知界」，旧域名已跳转到新地址。改名后前端按统一视觉规范（`web/DESIGN.md`，白底 + 单一券商红、分隔线列表、底部出处抽屉）全面重做。

提交物

Web 产品（主站）	https://youju-ai.pages.dev　用户端 `#/app`，运营后台 `#/ops`，打开即用，无需账号或 key
Web 产品（镜像）	https://neal122234.github.io/youju-ai-advisor-qa/　主站接口不可达时自动切浏览器内「本地演示模式」
源代码仓库	https://github.com/Neal122234/youju-ai-advisor-qa（压缩包内另附源码快照 `source.zip`）
README	仓库首页 / `README.md`：目标用户、核心设计、AI 角色、数据使用、已知边界与未做事项（含合规边界）
演示视频	`demo.mp4`（约 160 秒，1920×1080，配音 + 字幕；新 UI、线上真实模型录制），分镜 `demo-script.md`
AI 使用与验证记录	`docs/AI使用与验证记录.md`，评测迭代 `docs/eval-log.md`，盲测 `docs/holdout.md`
测试说明	`docs/测试说明.md`：主链路、数据/接口异常（故障注入）、合规边界用例与复现方法；三轮独立 QA 报告 `docs/qa-report-round1~3.md`（各含修复记录）

3 分钟体验路径

- 用户端右侧「演示控制台」可切风险等级 C1–C5、打开「展开技术详情」、选故障注入，并按类型点示例问题：**科创板开通条件**（「已核实来源 · 引用 N 处」，角标打开底部出处抽屉，C3 用户看到适当性提示，附推荐追问）→ **宁德时代还能上车吗**（「超出服务范围」+ 后台告警）→ **市盈率怎么看？茅台还能买吗**（「部分问题不在服务范围」）→ **基金赎回多久到账**（「已转人工」+ 工单）。
- 回答下方点「详情」：决策类型、置信度拆解；「完整追溯」跳到后台，看逐步校验时间线、检索命中块与分数、知识版本、模型与耗时。
- 后台「知识缺口」选中「基金赎回」→ 起草知识 → 发布 v2 → 回归验证，缺口关闭；「知识库」看版本 diff，已发布版本可「下线」，归档版本可回滚。评测页默认只跑前 8 题、不写入生产日志。
- 演示控制台「故障注入」选「大模型报错」：状态变为「知识库原文摘录」，降级作答，合规校验不失效。

核心设计

知识入库	Markdown + front-matter（类别、产品风险等级、出处、生效日）；按小标题切分，bge-m3 向量化；每次发布生成 release，答案记录所用版本
检索增强生成	向量 + BM25 混合检索；模型只依据资料作答，逐句标引用；逐句证据核验，无依据或含资料外数字的句子剔除

内置合规底线	每次问答必经；两层拦截：确定性规则引擎（荐股 / 预测 / 收益承诺 / 代客理财 / 内幕 / 隐私 / 注入）+ 规则放过时的 LLM 意图分类（只会多拦，不会放行）；输出侧再扫描；拒答话术取自知识库合规话术文档并引用
置信度与转人工	置信度 = 0.35 检索 + 0.25 覆盖 + 0.25 落地性 + 0.15 引用；≥0.62 作答，0.45–0.62 作答附核实提示，<0.45 或知识未覆盖则转人工，并且不展示模型生成内容
适当性	用户 C1–C5 与产品 R1–R5 比对，不匹配时给出提示；所有投资相关回答附统一风险提示
运营闭环	答不出 / 低置信 / 差评自动归并为知识缺口；越界触发告警；转人工生成工单 → 起草知识 → 发布新版本 → 回归验证 → 缺口关闭；版本可 diff、可回滚

验证结果

线上评测集	**120/123**　生产站干净 v1（2026-10-15）：正常 56/58、混合 11/11、越界 29/29、未知 10/11，注入、适当性、人工全满；评测数据保留在后台可查。未过的 3 题是凌晨上游模型慢、备用额度耗尽时，按设计降级为带出处的原文摘录，没有越界或编造
误判专项	70 句合理问题测"不该拦的有没有被拦"：修复前硬误判 9 句（12.9%）。按根因分层修复后，合理问题 14/14 不误拦，典型越界 13/13 仍拦截；行情与证券资料查询改为引导到 App，不告警、不记缺口
评测集外盲测	第三轮 10 句新问法：10/10 无越界、无编造（其中 1 处决策标签可优化，已写入已知边界）
单元测试	415 个用例全部通过（合规规则、切分、检索、置信度、管线异常、接口、三轮 QA 与误判专项回归、65 条推荐问题全量、三层模型回退），CI 测试不过则不发布
独立 QA	测试 agent 只测不改，修复 agent 修，下一轮 QA 独立复验。第 1 轮 161 个用例，25 个 Bug（修复 23 个，2 个转为已知边界）；第 2 轮（前端 UI + 新问法）97 个用例，20 个 Bug，全部处理；第 3 轮（README 逐步照做 + 探索）124 个用例，13 个 Bug（其中 P1 3 个，都是回答质量问题），全部修复。修复中曾两次引发评测回归，靠全量评测发现并修回
接口异常	LLM 故障或超时 → 降级为原文摘录；向量服务故障 → 只用关键词检索；数据库故障 → 照常作答并标注；限流返回 429
国内访问	站长工具 33 个国内节点（测的是同一基础设施的旧域名）：主站 24 个可访问（含杭州），镜像约 26 个；见 `docs/国内访问实测.md`

已知边界（摘要，详见 README）

- 演示后台没有登录和权限控制，写接口无鉴权、CORS 全开，为方便演示保留故障注入（生产环境需接入 RBAC、审批，并关闭故障注入）；chat 限流已改为 D1 全局计数。
- 模型通道三层回退：硅基流动 Qwen3-30B → Cloudflare Workers AI → 硅基流动 Qwen3-8B；投机并行后，走模型的问答平均约 3.6s，未做流式输出。上游慢且备用额度耗尽时，少数长答案会降级为原文摘录。换模型的工程改动很小，只改三项配置；但阈值按 Qwen3 校准，换模型要重跑全量评测、按原因修误判；合规底线是确定性代码，不受影响。
- 规则加 LLM 两层拦截仍做不到 100%，靠告警复盘和盲测持续补充；镜像的本地模式没有大模型，未知问题可能答非所问。
- 部分券商口径的数字（两融门槛、风险等级等）为示例，文中已标注「以交易所 / 券商最新规则为准」；系统没有接入真实行情和账户。

零成本部署：Cloudflare 免费额度（Pages Functions + D1 + Workers AI 备用通道）+ 硅基流动代金券（主通道按量计费，每次问答约 0.3 分钱量级，以账单为准）。仓库和文档中不含任何 key。