# 知界 · 合规投教助手

AI 投顾 / 智能问答运营与合规边界 · 场景：券商 App 内「投教助手」+ 运营后台（券商为虚构的「示例证券」，知识库为匿名构造）

## 提交物

| | |
|---|---|
| **Web 产品（主站）** | https://zhijie-qa.pages.dev　用户端 `#/app`，运营后台 `#/ops`，打开即用，无需账号或 key |
| **Web 产品（镜像）** | https://neal122234.github.io/zhijie-ai-advisor-qa/　主站接口不可达时自动切浏览器内「本地演示模式」 |
| **源代码仓库** | https://github.com/Neal122234/zhijie-ai-advisor-qa（压缩包内另附源码快照 `source.zip`） |
| **README** | 仓库首页 / `README.md`：目标用户、核心设计、AI 角色、数据使用、已知边界与未做事项（含合规边界） |
| **演示视频** | `demo.mp4`（约 168 秒，1080p，配音 + 字幕），分镜 `demo-script.md` |
| **AI 使用与验证记录** | `docs/AI使用与验证记录.md`，评测迭代 `docs/eval-log.md`，盲测 `docs/holdout.md` |
| **测试说明** | `docs/测试说明.md`：主链路、数据/接口异常（故障注入）、合规边界用例与复现方法 |

## 3 分钟体验路径

- 用户端点快捷问题：**科创板开通条件**（引用角标展开出处 + 置信度拆解 + 适当性提示）→ **宁德时代还能上车吗**（越界拒答 + 告警）→ **市盈率怎么看？茅台还能买吗**（部分拒答）→ **基金赎回多久到账**（知识未覆盖，转人工 + 工单）。
- 每条回答点「查看完整追溯」：逐步校验时间线、检索命中块与分数、知识版本、模型与耗时。
- 后台「知识缺口」选中「基金赎回」→ 起草知识 → 发布 v2 → 回归验证，缺口关闭；「知识库」看版本 diff、可回滚。
- 演示栏「故障注入」选 LLM 故障：系统降级为原文摘录作答，合规校验不失效。

## 核心设计

| | |
|---|---|
| **知识入库** | Markdown + front-matter（类别、产品风险等级、出处、生效日）；按小标题切分，bge-m3 向量化；每次发布生成 release，答案记录所用版本 |
| **检索增强生成** | 向量 + BM25 混合检索；模型只依据资料作答，逐句标引用；逐句证据核验，无依据或含资料外数字的句子剔除 |
| **合规边界** | 两层拦截：确定性规则引擎（荐股 / 预测 / 收益承诺 / 代客理财 / 内幕 / 隐私 / 注入）+ 规则放过时的 LLM 意图分类（只会多拦，不会放行）；输出侧再扫描；拒答话术取自知识库合规话术文档并引用 |
| **置信度与转人工** | 置信度 = 0.35 检索 + 0.25 覆盖 + 0.25 落地性 + 0.15 引用；≥0.62 作答，0.45–0.62 作答附核实提示，<0.45 或知识未覆盖则转人工，并且不展示模型生成内容 |
| **适当性** | 用户 C1–C5 与产品 R1–R5 比对，不匹配时给出提示；所有投资相关回答附统一风险提示 |
| **运营闭环** | 答不出 / 低置信 / 差评自动归并为知识缺口；越界触发告警；转人工生成工单 → 起草知识 → 发布新版本 → 回归验证 → 缺口关闭；版本可 diff、可回滚 |

## 验证结果

| | |
|---|---|
| **线上评测集** | **86/86**　正常 30、混合 10、越界 25、未知 9、注入 4、适当性 5、人工 3（真实模型，干净 release v1） |
| **评测集外盲测** | 第三轮 10 句新问法：10/10 无越界、无编造（其中 1 处决策标签可优化，已写入已知边界） |
| **单元测试** | 208 个用例全部通过（合规规则、切分、检索、置信度、管线异常、接口），CI 测试不过则不发布 |
| **接口异常** | LLM 故障或超时 → 降级为原文摘录；向量服务故障 → 只用关键词检索；数据库故障 → 照常作答并标注；限流返回 429 |
| **国内访问** | 站长工具 33 个国内节点：主站 24 个可访问（含杭州），镜像约 26 个；见 `docs/国内访问实测.md` |

## 已知边界（摘要，详见 README）

- 演示后台没有登录和权限控制（生产环境需接入 RBAC 与审批）；限流按单个 isolate 计数，不是全局限流；依赖 Cloudflare 免费额度。
- 规则加 LLM 两层拦截仍做不到 100%，靠告警复盘和盲测持续补充；镜像的本地模式没有大模型，未知问题可能答非所问。
- 部分券商口径的数字（两融门槛、风险等级等）为示例，文中已标注「以交易所 / 券商最新规则为准」；系统没有接入真实行情和账户。

全部使用免费资源：Cloudflare Pages Functions + D1 + Workers AI（qwen3-30b-a3b 生成与意图分类，bge-m3 向量）。